

LCOV - code coverage report

Current view: [top level](#) - [src/plugins/intel_cpu/src/nodes/kernels/scaled_attn](#) - [transpose_kernel.hpp](#) (source / functions)Test: [full_covergae.info](#)

Test Date: 2025-04-10 19:26:12

Coverage

Lines: 47.2 %

Functions: 28.6 %

Line data Source code

```
1 : // Copyright (C) 2018-2025 Intel Corporation
2 : // SPDX-License-Identifier: Apache-2.0
3 : //
4 : #pragma once
5 :
6 : #include <array>
7 : #include <cstdint>
8 : #include <cstdint>
9 : #include <vector>
10 :
11 : #include "common.hpp"
12 : #include "openvino/core/type/element_type.hpp"
13 :
14 : #if defined(HAVE_SVE)
15 : #include "arm_sve.h"
16 : #endif
17 :
18 : namespace ov::Extensions::Cpu::XARCH {
19 :
20 : #if defined(HAVE_AVX512F)
21 : inline void transpose_m512i_16x16(__m512i r0,
22 : __m512i r1,
23 : __m512i r2,
24 : __m512i r3,
25 : __m512i r4,
26 : __m512i r5,
27 : __m512i r6,
28 : __m512i r7,
29 : __m512i r8,
30 : __m512i r9,
31 : __m512i ra,
32 : __m512i rb,
33 : __m512i rc,
34 : __m512i rd,
35 : __m512i re,
36 : __m512i rf) {
37 :     __m512i t0, t1, t2, t3, t4, t5, t6, t7, t8, t9, ta, tb, tc, td, te, tf;
38 :
39 :     t0 = _mm512_unpacklo_epi32(r0, r1); // 0 16 1 17 4 20 5 21 8 24 9 25 12 28 13 29
40 :     t1 = _mm512_unpackhi_epi32(r0, r1); // 2 18 3 19 6 22 7 23 10 26 11 27 14 30 15 31
41 :     t2 = _mm512_unpacklo_epi32(r2, r3); // 32 48 33 49 ...
42 :     t3 = _mm512_unpackhi_epi32(r2, r3); // 34 50 35 51 ...
43 :     t4 = _mm512_unpacklo_epi32(r4, r5); // 64 80 65 81 ...
44 :     t5 = _mm512_unpackhi_epi32(r4, r5); // 66 82 67 83 ...
45 :     t6 = _mm512_unpacklo_epi32(r6, r7); // 96 112 97 113 ...
46 :     t7 = _mm512_unpackhi_epi32(r6, r7); // 98 114 99 115 ...
47 :     t8 = _mm512_unpacklo_epi32(r8, r9); // 128 ...
48 :     t9 = _mm512_unpackhi_epi32(r8, r9); // 130 ...
49 :     ta = _mm512_unpacklo_epi32(ra, rb); // 160 ...
50 :     tb = _mm512_unpackhi_epi32(ra, rb); // 162 ...
51 :     tc = _mm512_unpacklo_epi32(rc, rd); // 196 ...
52 :     td = _mm512_unpackhi_epi32(rc, rd); // 198 ...
53 :     te = _mm512_unpacklo_epi32(re, rf); // 228 ...
54 :     tf = _mm512_unpackhi_epi32(re, rf); // 230 ...
55 :
56 :     r0 = _mm512_unpacklo_epi64(t0, t2); // 0 16 32 48 ...
57 :     r1 = _mm512_unpackhi_epi64(t0, t2); // 1 17 33 49 ...
58 :     r2 = _mm512_unpacklo_epi64(t1, t3); // 2 18 34 49 ...
59 :     r3 = _mm512_unpackhi_epi64(t1, t3); // 3 19 35 51 ...
60 :     r4 = _mm512_unpacklo_epi64(t4, t6); // 64 80 96 112 ...
61 :     r5 = _mm512_unpackhi_epi64(t4, t6); // 65 81 97 114 ...
62 :     r6 = _mm512_unpacklo_epi64(t5, t7); // 66 82 98 113 ...
63 :     r7 = _mm512_unpackhi_epi64(t5, t7); // 67 83 99 115 ...
64 :     r8 = _mm512_unpacklo_epi64(t8, ta); // 128 144 160 176 ...
65 :     r9 = _mm512_unpackhi_epi64(t8, ta); // 129 145 161 178 ...
66 :     ra = _mm512_unpacklo_epi64(t9, tb); // 130 146 162 177 ...
67 :     rb = _mm512_unpackhi_epi64(t9, tb); // 131 147 163 179 ...
68 :     rc = _mm512_unpacklo_epi64(tc, te); // 192 208 228 240 ...
69 :     rd = _mm512_unpackhi_epi64(tc, te); // 193 209 229 241 ...
70 :     re = _mm512_unpacklo_epi64(td, tf); // 194 210 230 242 ...
71 :     rf = _mm512_unpackhi_epi64(td, tf); // 195 211 231 243 ...
72 :
73 :     t0 = _mm512_shuffle_i32x4(r0, r4, 0x88); // 0 16 32 48 8 24 40 56 64 80 96 112 ...
74 :     t1 = _mm512_shuffle_i32x4(r1, r5, 0x88); // 1 17 33 49 ...
75 :     t2 = _mm512_shuffle_i32x4(r2, r6, 0x88); // 2 18 34 50 ...
76 :     t3 = _mm512_shuffle_i32x4(r3, r7, 0x88); // 3 19 35 51 ...
77 :     t4 = _mm512_shuffle_i32x4(r0, r4, 0xdd); // 4 20 36 52 ...
78 :     t5 = _mm512_shuffle_i32x4(r1, r5, 0xdd); // 5 21 37 53 ...
79 :     t6 = _mm512_shuffle_i32x4(r2, r6, 0xdd); // 6 22 38 54 ...
80 :     t7 = _mm512_shuffle_i32x4(r3, r7, 0xdd); // 7 23 39 55 ...
81 :     t8 = _mm512_shuffle_i32x4(r8, rc, 0x88); // 128 144 160 176 ...
82 :     t9 = _mm512_shuffle_i32x4(r9, rd, 0x88); // 129 145 161 177 ...
83 :     ta = _mm512_shuffle_i32x4(ra, re, 0x88); // 130 146 162 178 ...
84 :     tb = _mm512_shuffle_i32x4(rb, rf, 0x88); // 131 147 163 179 ...
85 :     tc = _mm512_shuffle_i32x4(r8, rc, 0xdd); // 132 148 164 180 ...
86 :     td = _mm512_shuffle_i32x4(r9, rd, 0xdd); // 133 149 165 181 ...
87 :     te = _mm512_shuffle_i32x4(ra, re, 0xdd); // 134 150 166 182 ...
88 :     tf = _mm512_shuffle_i32x4(rb, rf, 0xdd); // 135 151 167 183 ...
89 :
90 :     r0 = _mm512_shuffle_i32x4(t0, t8, 0x88); // 0 16 32 48 64 80 96 112 ... 240
91 :     r1 = _mm512_shuffle_i32x4(t1, t9, 0x88); // 1 17 33 49 65 81 97 113 ... 241
92 :     r2 = _mm512_shuffle_i32x4(t2, ta, 0x88); // 2 18 34 50 67 82 98 114 ... 242
93 :     r3 = _mm512_shuffle_i32x4(t3, tb, 0x88); // 3 19 35 51 68 83 99 115 ... 243
```

```

94 : r4 = _mm512_shuffle_i32x4(t4, tc, 0x88); // 4 ...
95 : r5 = _mm512_shuffle_i32x4(t5, td, 0x88); // 5 ...
96 : r6 = _mm512_shuffle_i32x4(t6, te, 0x88); // 6 ...
97 : r7 = _mm512_shuffle_i32x4(t7, tf, 0x88); // 7 ...
98 : r8 = _mm512_shuffle_i32x4(t0, t8, 0xdd); // 8 ...
99 : r9 = _mm512_shuffle_i32x4(t1, t9, 0xdd); // 9 ...
100 : ra = _mm512_shuffle_i32x4(t2, ta, 0xdd); // 10 ...
101 : rb = _mm512_shuffle_i32x4(t3, tb, 0xdd); // 11 ...
102 : rc = _mm512_shuffle_i32x4(t4, tc, 0xdd); // 12 ...
103 : rd = _mm512_shuffle_i32x4(t5, td, 0xdd); // 13 ...
104 : re = _mm512_shuffle_i32x4(t6, te, 0xdd); // 14 ...
105 : rf = _mm512_shuffle_i32x4(t7, tf, 0xdd); // 15 31 47 63 79 96 111 127 ... 255
106 : }
107 :
108 : template <typename T>
109 : inline void transpose_16x16_kernel(float* _dst, T* src, size_t dst_stride, size_t src_stride) {
110 :     auto* dst = reinterpret_cast<uint32_t*>(_dst);
111 :     _mm512i r0, r1, r2, r3, r4, r5, r6, r7, r8, r9, ra, rb, rc, rd, re, rf;
112 :     r0 = _mm512_castps_si512(mm512_uni_loadu_ps(src));
113 :     r1 = _mm512_castps_si512(mm512_uni_loadu_ps(src + src_stride));
114 :     r2 = _mm512_castps_si512(mm512_uni_loadu_ps(src + 2 * src_stride));
115 :     r3 = _mm512_castps_si512(mm512_uni_loadu_ps(src + 3 * src_stride));
116 :     r4 = _mm512_castps_si512(mm512_uni_loadu_ps(src + 4 * src_stride));
117 :     r5 = _mm512_castps_si512(mm512_uni_loadu_ps(src + 5 * src_stride));
118 :     r6 = _mm512_castps_si512(mm512_uni_loadu_ps(src + 6 * src_stride));
119 :     r7 = _mm512_castps_si512(mm512_uni_loadu_ps(src + 7 * src_stride));
120 :     r8 = _mm512_castps_si512(mm512_uni_loadu_ps(src + 8 * src_stride));
121 :     r9 = _mm512_castps_si512(mm512_uni_loadu_ps(src + 9 * src_stride));
122 :     ra = _mm512_castps_si512(mm512_uni_loadu_ps(src + 10 * src_stride));
123 :     rb = _mm512_castps_si512(mm512_uni_loadu_ps(src + 11 * src_stride));
124 :     rc = _mm512_castps_si512(mm512_uni_loadu_ps(src + 12 * src_stride));
125 :     rd = _mm512_castps_si512(mm512_uni_loadu_ps(src + 13 * src_stride));
126 :     re = _mm512_castps_si512(mm512_uni_loadu_ps(src + 14 * src_stride));
127 :     rf = _mm512_castps_si512(mm512_uni_loadu_ps(src + 15 * src_stride));
128 :
129 :     transpose_mm512i_16x16(r0, r1, r2, r3, r4, r5, r6, r7, r8, r9, ra, rb, rc, rd, re, rf);
130 :
131 :     _mm512_storeu_si512(dst, r0);
132 :     _mm512_storeu_si512(dst + dst_stride, r1);
133 :     _mm512_storeu_si512(dst + 2 * dst_stride, r2);
134 :     _mm512_storeu_si512(dst + 3 * dst_stride, r3);
135 :     _mm512_storeu_si512(dst + 4 * dst_stride, r4);
136 :     _mm512_storeu_si512(dst + 5 * dst_stride, r5);
137 :     _mm512_storeu_si512(dst + 6 * dst_stride, r6);
138 :     _mm512_storeu_si512(dst + 7 * dst_stride, r7);
139 :     _mm512_storeu_si512(dst + 8 * dst_stride, r8);
140 :     _mm512_storeu_si512(dst + 9 * dst_stride, r9);
141 :     _mm512_storeu_si512(dst + 10 * dst_stride, ra);
142 :     _mm512_storeu_si512(dst + 11 * dst_stride, rb);
143 :     _mm512_storeu_si512(dst + 12 * dst_stride, rc);
144 :     _mm512_storeu_si512(dst + 13 * dst_stride, rd);
145 :     _mm512_storeu_si512(dst + 14 * dst_stride, re);
146 :     _mm512_storeu_si512(dst + 15 * dst_stride, rf);
147 : }
148 :
149 : template <typename T>
150 : inline void transpose_16xK_kernel(float* _dst, T* src, size_t K, size_t dst_stride, size_t src_stride) {
151 :     auto* dst = reinterpret_cast<uint32_t*>(_dst);
152 :     _mm512i r0, r1, r2, r3, r4, r5, r6, r7, r8, r9, ra, rb, rc, rd, re, rf;
153 :     r0 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src, K));
154 :     r1 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + src_stride, K));
155 :     r2 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 2 * src_stride, K));
156 :     r3 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 3 * src_stride, K));
157 :     r4 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 4 * src_stride, K));
158 :     r5 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 5 * src_stride, K));
159 :     r6 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 6 * src_stride, K));
160 :     r7 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 7 * src_stride, K));
161 :     r8 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 8 * src_stride, K));
162 :     r9 = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 9 * src_stride, K));
163 :     ra = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 10 * src_stride, K));
164 :     rb = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 11 * src_stride, K));
165 :     rc = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 12 * src_stride, K));
166 :     rd = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 13 * src_stride, K));
167 :     re = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 14 * src_stride, K));
168 :     rf = _mm512_castps_si512(mm512_uni_loadu_tail_ps(src + 15 * src_stride, K));
169 :
170 :     transpose_mm512i_16x16(r0, r1, r2, r3, r4, r5, r6, r7, r8, r9, ra, rb, rc, rd, re, rf);
171 :
172 : # define S(m) _mm512_storeu_si512(dst + 0x##m * dst_stride, r##m)
173 : # define S8() \
174 :     S(0); \
175 :     S(1); \
176 :     S(2); \
177 :     S(3); \
178 :     S(4); \
179 :     S(5); \
180 :     S(6); \
181 :     S(7);
182 :     switch (K) {
183 :     case 8:
184 :         S8();
185 :         break;
186 :     case 9:
187 :         S8() S(8);
188 :         break;
189 :     case 10:
190 :         S8();
191 :         S(8);
192 :         S(9);
193 :         break;
194 :     case 11:
195 :         S8();
196 :         S(8);
197 :         S(9);

```

```

198 :         S(a);
199 :         break;
200 :     case 12:
201 :         S8();
202 :         S(8);
203 :         S(9);
204 :         S(a);
205 :         S(b);
206 :         break;
207 :     case 13:
208 :         S8();
209 :         S(8);
210 :         S(9);
211 :         S(a);
212 :         S(b);
213 :         S(c);
214 :         break;
215 :     case 14:
216 :         S8();
217 :         S(8);
218 :         S(9);
219 :         S(a);
220 :         S(b);
221 :         S(c);
222 :         S(d);
223 :         break;
224 :     case 15:
225 :         S8();
226 :         S(8);
227 :         S(9);
228 :         S(a);
229 :         S(b);
230 :         S(c);
231 :         S(d);
232 :         S(e);
233 :         break;
234 :     case 1:
235 :         S(0);
236 :         break;
237 :     case 2:
238 :         S(0);
239 :         S(1);
240 :         break;
241 :     case 3:
242 :         S(0);
243 :         S(1);
244 :         S(2);
245 :         break;
246 :     case 4:
247 :         S(0);
248 :         S(1);
249 :         S(2);
250 :         S(3);
251 :         break;
252 :     case 5:
253 :         S(0);
254 :         S(1);
255 :         S(2);
256 :         S(3);
257 :         S(4);
258 :         break;
259 :     case 6:
260 :         S(0);
261 :         S(1);
262 :         S(2);
263 :         S(3);
264 :         S(4);
265 :         S(5);
266 :         break;
267 :     case 7:
268 :         S(0);
269 :         S(1);
270 :         S(2);
271 :         S(3);
272 :         S(4);
273 :         S(5);
274 :         S(6);
275 :         break;
276 :     }
277 : }
278 :
279 : inline void transpose_16x16_kernel(uint32_t* dst, uint32_t* src, size_t dst_stride, size_t src_stride) {
280 :     __m512i r0, r1, r2, r3, r4, r5, r6, r7, r8, r9, ra, rb, rc, rd, re, rf;
281 :     r0 = _mm512_loadu_si512(src);
282 :     r1 = _mm512_loadu_si512(src + src_stride);
283 :     r2 = _mm512_loadu_si512(src + 2 * src_stride);
284 :     r3 = _mm512_loadu_si512(src + 3 * src_stride);
285 :     r4 = _mm512_loadu_si512(src + 4 * src_stride);
286 :     r5 = _mm512_loadu_si512(src + 5 * src_stride);
287 :     r6 = _mm512_loadu_si512(src + 6 * src_stride);
288 :     r7 = _mm512_loadu_si512(src + 7 * src_stride);
289 :     r8 = _mm512_loadu_si512(src + 8 * src_stride);
290 :     r9 = _mm512_loadu_si512(src + 9 * src_stride);
291 :     ra = _mm512_loadu_si512(src + 10 * src_stride);
292 :     rb = _mm512_loadu_si512(src + 11 * src_stride);
293 :     rc = _mm512_loadu_si512(src + 12 * src_stride);
294 :     rd = _mm512_loadu_si512(src + 13 * src_stride);
295 :     re = _mm512_loadu_si512(src + 14 * src_stride);
296 :     rf = _mm512_loadu_si512(src + 15 * src_stride);
297 :
298 :     transpose_m512i_16x16(r0, r1, r2, r3, r4, r5, r6, r7, r8, r9, ra, rb, rc, rd, re, rf);
299 :
300 :     _mm512_storeu_si512(dst, r0);
301 :     _mm512_storeu_si512(dst + dst_stride, r1);

```

```

302 :     _mm512_storeu_si512(dst + 2 * dst_stride, r2);
303 :     _mm512_storeu_si512(dst + 3 * dst_stride, r3);
304 :     _mm512_storeu_si512(dst + 4 * dst_stride, r4);
305 :     _mm512_storeu_si512(dst + 5 * dst_stride, r5);
306 :     _mm512_storeu_si512(dst + 6 * dst_stride, r6);
307 :     _mm512_storeu_si512(dst + 7 * dst_stride, r7);
308 :     _mm512_storeu_si512(dst + 8 * dst_stride, r8);
309 :     _mm512_storeu_si512(dst + 9 * dst_stride, r9);
310 :     _mm512_storeu_si512(dst + 10 * dst_stride, ra);
311 :     _mm512_storeu_si512(dst + 11 * dst_stride, rb);
312 :     _mm512_storeu_si512(dst + 12 * dst_stride, rc);
313 :     _mm512_storeu_si512(dst + 13 * dst_stride, rd);
314 :     _mm512_storeu_si512(dst + 14 * dst_stride, re);
315 :     _mm512_storeu_si512(dst + 15 * dst_stride, rf);
316 : }
317 :
318 : inline void transpose_16xK_kernel(uint32_t* dst, uint32_t* src, size_t K, size_t dst_stride, size_t src_stride) {
319 :     _mm512i r0, r1, r2, r3, r4, r5, r6, r7, r8, r9, ra, rb, rc, rd, re, rf;
320 :     __m16k k = 0xffff >> (16 - K);
321 :
322 :     r0 = _mm512_maskz_loadu_epi32(k, src);
323 :     r1 = _mm512_maskz_loadu_epi32(k, src + src_stride);
324 :     r2 = _mm512_maskz_loadu_epi32(k, src + 2 * src_stride);
325 :     r3 = _mm512_maskz_loadu_epi32(k, src + 3 * src_stride);
326 :     r4 = _mm512_maskz_loadu_epi32(k, src + 4 * src_stride);
327 :     r5 = _mm512_maskz_loadu_epi32(k, src + 5 * src_stride);
328 :     r6 = _mm512_maskz_loadu_epi32(k, src + 6 * src_stride);
329 :     r7 = _mm512_maskz_loadu_epi32(k, src + 7 * src_stride);
330 :     r8 = _mm512_maskz_loadu_epi32(k, src + 8 * src_stride);
331 :     r9 = _mm512_maskz_loadu_epi32(k, src + 9 * src_stride);
332 :     ra = _mm512_maskz_loadu_epi32(k, src + 10 * src_stride);
333 :     rb = _mm512_maskz_loadu_epi32(k, src + 11 * src_stride);
334 :     rc = _mm512_maskz_loadu_epi32(k, src + 12 * src_stride);
335 :     rd = _mm512_maskz_loadu_epi32(k, src + 13 * src_stride);
336 :     re = _mm512_maskz_loadu_epi32(k, src + 14 * src_stride);
337 :     rf = _mm512_maskz_loadu_epi32(k, src + 15 * src_stride);
338 :
339 :     transpose_m512i_16x16(r0, r1, r2, r3, r4, r5, r6, r7, r8, r9, ra, rb, rc, rd, re, rf);
340 :
341 :     switch (K) {
342 :     case 8:
343 :         S8();
344 :         break;
345 :     case 9:
346 :         S8() S(8);
347 :         break;
348 :     case 10:
349 :         S8();
350 :         S(8);
351 :         S(9);
352 :         break;
353 :     case 11:
354 :         S8();
355 :         S(8);
356 :         S(9);
357 :         S(a);
358 :         break;
359 :     case 12:
360 :         S8();
361 :         S(8);
362 :         S(9);
363 :         S(a);
364 :         S(b);
365 :         break;
366 :     case 13:
367 :         S8();
368 :         S(8);
369 :         S(9);
370 :         S(a);
371 :         S(b);
372 :         S(c);
373 :         break;
374 :     case 14:
375 :         S8();
376 :         S(8);
377 :         S(9);
378 :         S(a);
379 :         S(b);
380 :         S(c);
381 :         S(d);
382 :         break;
383 :     case 15:
384 :         S8();
385 :         S(8);
386 :         S(9);
387 :         S(a);
388 :         S(b);
389 :         S(c);
390 :         S(d);
391 :         S(e);
392 :         break;
393 :     case 1:
394 :         S(0);
395 :         break;
396 :     case 2:
397 :         S(0);
398 :         S(1);
399 :         break;
400 :     case 3:
401 :         S(0);
402 :         S(1);
403 :         S(2);
404 :         break;
405 :     case 4:

```

```

406 :         S(0);
407 :         S(1);
408 :         S(2);
409 :         S(3);
410 :         break;
411 :     case 5:
412 :         S(0);
413 :         S(1);
414 :         S(2);
415 :         S(3);
416 :         S(4);
417 :         break;
418 :     case 6:
419 :         S(0);
420 :         S(1);
421 :         S(2);
422 :         S(3);
423 :         S(4);
424 :         S(5);
425 :         break;
426 :     case 7:
427 :         S(0);
428 :         S(1);
429 :         S(2);
430 :         S(3);
431 :         S(4);
432 :         S(5);
433 :         S(6);
434 :         break;
435 :     }
436 : #   undef S
437 : #   undef S8
438 : }
439 :
440 : #elif defined(HAVE_AVX2)
441 :
442 : // https://stackoverflow.com/questions/25622745/transpose-an-8x8-float-using-avx-avx2
443 : inline void
444 : transpose_8x8(__m256& r0, __m256& r1, __m256& r2, __m256& r3, __m256& r4, __m256& r5, __m256& r6, __m256& r7) {
445 :     __m256 t0, t1, t2, t3, t4, t5, t6, t7;
446 :     __m256 tt0, tt1, tt2, tt3, tt4, tt5, tt6, tt7;
447 :     t0 = _mm256_unpacklo_ps(r0, r1);
448 :     t1 = _mm256_unpackhi_ps(r0, r1);
449 :     t2 = _mm256_unpacklo_ps(r2, r3);
450 :     t3 = _mm256_unpackhi_ps(r2, r3);
451 :     t4 = _mm256_unpacklo_ps(r4, r5);
452 :     t5 = _mm256_unpackhi_ps(r4, r5);
453 :     t6 = _mm256_unpacklo_ps(r6, r7);
454 :     t7 = _mm256_unpackhi_ps(r6, r7);
455 :     tt0 = _mm256_shuffle_ps(t0, t2, _MM_SHUFFLE(1, 0, 1, 0));
456 :     tt1 = _mm256_shuffle_ps(t0, t2, _MM_SHUFFLE(3, 2, 3, 2));
457 :     tt2 = _mm256_shuffle_ps(t1, t3, _MM_SHUFFLE(1, 0, 1, 0));
458 :     tt3 = _mm256_shuffle_ps(t1, t3, _MM_SHUFFLE(3, 2, 3, 2));
459 :     tt4 = _mm256_shuffle_ps(t4, t6, _MM_SHUFFLE(1, 0, 1, 0));
460 :     tt5 = _mm256_shuffle_ps(t4, t6, _MM_SHUFFLE(3, 2, 3, 2));
461 :     tt6 = _mm256_shuffle_ps(t5, t7, _MM_SHUFFLE(1, 0, 1, 0));
462 :     tt7 = _mm256_shuffle_ps(t5, t7, _MM_SHUFFLE(3, 2, 3, 2));
463 :     r0 = _mm256_permute2f128_ps(tt0, tt4, 0x20);
464 :     r1 = _mm256_permute2f128_ps(tt1, tt5, 0x20);
465 :     r2 = _mm256_permute2f128_ps(tt2, tt6, 0x20);
466 :     r3 = _mm256_permute2f128_ps(tt3, tt7, 0x20);
467 :     r4 = _mm256_permute2f128_ps(tt0, tt4, 0x31);
468 :     r5 = _mm256_permute2f128_ps(tt1, tt5, 0x31);
469 :     r6 = _mm256_permute2f128_ps(tt2, tt6, 0x31);
470 :     r7 = _mm256_permute2f128_ps(tt3, tt7, 0x31);
471 : }
472 :
473 : template <typename T>
474 : inline void transpose_16x16_kernel(float* dst, T* src, size_t dst_stride, size_t src_stride) {
475 :     __m256 r0, r1, r2, r3, r4, r5, r6, r7;
476 :
477 :     for (int i = 0; i < 16; i += 8) {
478 :         for (int j = 0; j < 16; j += 8) {
479 :             r0 = mm256_uni_loadu_ps(src + src_stride * j);
480 :             r1 = mm256_uni_loadu_ps(src + src_stride * (1 + j));
481 :             r2 = mm256_uni_loadu_ps(src + src_stride * (2 + j));
482 :             r3 = mm256_uni_loadu_ps(src + src_stride * (3 + j));
483 :             r4 = mm256_uni_loadu_ps(src + src_stride * (4 + j));
484 :             r5 = mm256_uni_loadu_ps(src + src_stride * (5 + j));
485 :             r6 = mm256_uni_loadu_ps(src + src_stride * (6 + j));
486 :             r7 = mm256_uni_loadu_ps(src + src_stride * (7 + j));
487 :
488 :             transpose_8x8(r0, r1, r2, r3, r4, r5, r6, r7);
489 :
490 :             _mm256_storeu_ps(dst + j, r0);
491 :             _mm256_storeu_ps(dst + j + dst_stride, r1);
492 :             _mm256_storeu_ps(dst + j + dst_stride * 2, r2);
493 :             _mm256_storeu_ps(dst + j + dst_stride * 3, r3);
494 :             _mm256_storeu_ps(dst + j + dst_stride * 4, r4);
495 :             _mm256_storeu_ps(dst + j + dst_stride * 5, r5);
496 :             _mm256_storeu_ps(dst + j + dst_stride * 6, r6);
497 :             _mm256_storeu_ps(dst + j + dst_stride * 7, r7);
498 :         }
499 :         src += 8;
500 :         dst += 8 * dst_stride;
501 :     }
502 : }
503 :
504 : template <typename T>
505 : inline void transpose_16xK_kernel(float* dst, T* src, size_t K, size_t dst_stride, size_t src_stride) {
506 :     __m256 r0, r1, r2, r3, r4, r5, r6, r7;
507 :
508 :     if (K >= 8) {
509 :         for (int j = 0; j < 16; j += 8) {

```

```

510 :         r0 = mm256_uni_loadu_ps(src + src_stride * j);
511 :         r1 = mm256_uni_loadu_ps(src + src_stride * (1 + j));
512 :         r2 = mm256_uni_loadu_ps(src + src_stride * (2 + j));
513 :         r3 = mm256_uni_loadu_ps(src + src_stride * (3 + j));
514 :         r4 = mm256_uni_loadu_ps(src + src_stride * (4 + j));
515 :         r5 = mm256_uni_loadu_ps(src + src_stride * (5 + j));
516 :         r6 = mm256_uni_loadu_ps(src + src_stride * (6 + j));
517 :         r7 = mm256_uni_loadu_ps(src + src_stride * (7 + j));
518 :
519 :         transpose_8x8(r0, r1, r2, r3, r4, r5, r6, r7);
520 :
521 :         _mm256_storeu_ps(dst + j, r0);
522 :         _mm256_storeu_ps(dst + j + dst_stride, r1);
523 :         _mm256_storeu_ps(dst + j + dst_stride * 2, r2);
524 :         _mm256_storeu_ps(dst + j + dst_stride * 3, r3);
525 :         _mm256_storeu_ps(dst + j + dst_stride * 4, r4);
526 :         _mm256_storeu_ps(dst + j + dst_stride * 5, r5);
527 :         _mm256_storeu_ps(dst + j + dst_stride * 6, r6);
528 :         _mm256_storeu_ps(dst + j + dst_stride * 7, r7);
529 :     }
530 :     src += 8;
531 :     dst += 8 * dst_stride;
532 :     K -= 8;
533 : }
534 : if (K > 0) {
535 :     for (int j = 0; j < 16; j += 8) {
536 :         r0 = mm256_uni_loadu_tail_ps(src + src_stride * j, K);
537 :         r1 = mm256_uni_loadu_tail_ps(src + src_stride * (1 + j), K);
538 :         r2 = mm256_uni_loadu_tail_ps(src + src_stride * (2 + j), K);
539 :         r3 = mm256_uni_loadu_tail_ps(src + src_stride * (3 + j), K);
540 :         r4 = mm256_uni_loadu_tail_ps(src + src_stride * (4 + j), K);
541 :         r5 = mm256_uni_loadu_tail_ps(src + src_stride * (5 + j), K);
542 :         r6 = mm256_uni_loadu_tail_ps(src + src_stride * (6 + j), K);
543 :         r7 = mm256_uni_loadu_tail_ps(src + src_stride * (7 + j), K);
544 :
545 :         transpose_8x8(r0, r1, r2, r3, r4, r5, r6, r7);
546 :
547 : #     define S(m) _mm256_storeu_ps(dst + j + m * dst_stride, r##m)
548 :         switch (K) {
549 :             case 1:
550 :                 S(0);
551 :                 break;
552 :             case 2:
553 :                 S(0);
554 :                 S(1);
555 :                 break;
556 :             case 3:
557 :                 S(0);
558 :                 S(1);
559 :                 S(2);
560 :                 break;
561 :             case 4:
562 :                 S(0);
563 :                 S(1);
564 :                 S(2);
565 :                 S(3);
566 :                 break;
567 :             case 5:
568 :                 S(0);
569 :                 S(1);
570 :                 S(2);
571 :                 S(3);
572 :                 S(4);
573 :                 break;
574 :             case 6:
575 :                 S(0);
576 :                 S(1);
577 :                 S(2);
578 :                 S(3);
579 :                 S(4);
580 :                 S(5);
581 :                 break;
582 :             case 7:
583 :                 S(0);
584 :                 S(1);
585 :                 S(2);
586 :                 S(3);
587 :                 S(4);
588 :                 S(5);
589 :                 S(6);
590 :                 break;
591 :         }
592 : #     undef S
593 :     }
594 : }
595 : }
596 :
597 : #elif defined(HAVE_SVE)
598 : template <typename TSRC, typename TDST>
599 : inline void transpose_16x16_kernel(TDST* dst, TSRC* src, size_t dst_stride, size_t src_stride) {
600 :     for (size_t i = 0; i < 16; i++) {
601 :         for (size_t j = 0; j < 16; j++) {
602 :             dst[i * dst_stride + j] = static_cast<TDST>(src[i + j * src_stride]);
603 :         }
604 :     }
605 : }
606 :
607 : template <typename TSRC, typename TDST>
608 : inline void transpose_16xK_kernel(TDST* dst, TSRC* src, size_t K, size_t dst_stride, size_t src_stride) {
609 :     for (size_t i = 0; i < K; i++) {
610 :         for (size_t j = 0; j < 16; j++) {
611 :             dst[i * dst_stride + j] = static_cast<TDST>(src[i + j * src_stride]);
612 :         }
613 :     }

```

```

614 : 0 : }
615 :
616 : 85031 : inline void transpose_8x16_kernel(float16_t* dst, float16_t* src, size_t dst_stride, size_t src_stride) {
617 : // load 8 rows of 16 elements
618 : // a -> a0 a1 a2 a3 a4 a5 a6 a7 a8 ...
619 : // b -> b0 b1 b2 b3 b4 b5 b6 b7 b8 ...
620 : // c -> c0 c1 c2 c3 c4 c5 c6 c7 c8 ...
621 : // d -> d0 d1 d2 d3 d4 d5 d6 d7 d8 ...
622 : // ...
623 : 85031 : auto a = svld1_f16(svptrue_b16(), src);
624 : 85031 : auto b = svld1_f16(svptrue_b16(), src + 1 * src_stride);
625 : 85031 : auto c = svld1_f16(svptrue_b16(), src + 2 * src_stride);
626 : 85031 : auto d = svld1_f16(svptrue_b16(), src + 3 * src_stride);
627 : 85031 : auto e = svld1_f16(svptrue_b16(), src + 4 * src_stride);
628 : 85031 : auto f = svld1_f16(svptrue_b16(), src + 5 * src_stride);
629 : 85031 : auto g = svld1_f16(svptrue_b16(), src + 6 * src_stride);
630 : 85031 : auto h = svld1_f16(svptrue_b16(), src + 7 * src_stride);
631 :
632 : // a -> a0 b0 | a2 b2 | a4 b4 | a6 b6 | a8 b8 ...
633 : // b -> a1 b1 | a3 b3 | a5 b5 | a7 b7 | a9 b9 ...
634 : // c -> c0 d0 | c2 d2 | c4 d6 | c6 d8 | c8 d8 ...
635 : // d -> c1 d1 | c3 d3 | c5 d5 | c7 d7 | c9 d9 ...
636 : // ...
637 :
638 : 85031 : auto ta = svtrn1_f16(a, b);
639 : 85031 : auto tb = svtrn2_f16(a, b);
640 : 85031 : auto tc = svtrn1_f16(c, d);
641 : 85031 : auto td = svtrn2_f16(c, d);
642 : 85031 : auto te = svtrn1_f16(e, f);
643 : 85031 : auto tf = svtrn2_f16(e, f);
644 : 85031 : auto tg = svtrn1_f16(g, h);
645 : 85031 : auto th = svtrn2_f16(g, h);
646 :
647 : // a -> a0 b0 c0 d0 | a4 b4 c4 d6 | a8 b8 ...
648 : // b -> a2 b2 c2 d2 | a6 b6 c6 d8 | c8 d8 ...
649 : // c -> a1 b1 c1 d1 | a5 b5 c5 d5 | a9 b9 ...
650 : // d -> a3 b3 c3 d3 | a7 b7 c7 d7 | c9 d9 ...
651 : // ...
652 :
653 : 85031 : auto a1 = svtrn1_f32(svreinterpret_f32_f16(ta), svreinterpret_f32_f16(tc));
654 : 85031 : auto b1 = svtrn2_f32(svreinterpret_f32_f16(ta), svreinterpret_f32_f16(tc));
655 : 85031 : auto c1 = svtrn1_f32(svreinterpret_f32_f16(tb), svreinterpret_f32_f16(td));
656 : 85031 : auto d1 = svtrn2_f32(svreinterpret_f32_f16(tb), svreinterpret_f32_f16(td));
657 : 85031 : auto e1 = svtrn1_f32(svreinterpret_f32_f16(te), svreinterpret_f32_f16(tg));
658 : 85031 : auto f1 = svtrn2_f32(svreinterpret_f32_f16(te), svreinterpret_f32_f16(tg));
659 : 85031 : auto g1 = svtrn1_f32(svreinterpret_f32_f16(tf), svreinterpret_f32_f16(th));
660 : 85031 : auto h1 = svtrn2_f32(svreinterpret_f32_f16(tf), svreinterpret_f32_f16(th));
661 :
662 : 85031 : auto a2 = svtrn1_f64(svreinterpret_f64_f32(a1), svreinterpret_f64_f32(e1));
663 : 85031 : auto b2 = svtrn2_f64(svreinterpret_f64_f32(a1), svreinterpret_f64_f32(e1));
664 : 85031 : auto c2 = svtrn1_f64(svreinterpret_f64_f32(b1), svreinterpret_f64_f32(f1));
665 : 85031 : auto d2 = svtrn2_f64(svreinterpret_f64_f32(b1), svreinterpret_f64_f32(f1));
666 : 85031 : auto e2 = svtrn1_f64(svreinterpret_f64_f32(c1), svreinterpret_f64_f32(g1));
667 : 85031 : auto f2 = svtrn2_f64(svreinterpret_f64_f32(c1), svreinterpret_f64_f32(g1));
668 : 85031 : auto g2 = svtrn1_f64(svreinterpret_f64_f32(d1), svreinterpret_f64_f32(h1));
669 : 85031 : auto h2 = svtrn2_f64(svreinterpret_f64_f32(d1), svreinterpret_f64_f32(h1));
670 :
671 : 85031 : auto pgh = svnot_b_z(svptrue_b64(), svptrue_pat_b64(SV_VL2));
672 : 85031 : auto pgl = svptrue_pat_b64(SV_VL2);
673 : 85031 : svst1_f64(pgl, reinterpret_cast<float64_t*>(dst), a2);
674 : 76516 : svst1_f64(pgl, reinterpret_cast<float64_t*>(dst + dst_stride * 1), e2);
675 : 76516 : svst1_f64(pgl, reinterpret_cast<float64_t*>(dst + dst_stride * 2), c2);
676 : 76522 : svst1_f64(pgl, reinterpret_cast<float64_t*>(dst + dst_stride * 3), g2);
677 : 76522 : svst1_f64(pgl, reinterpret_cast<float64_t*>(dst + dst_stride * 4), b2);
678 : 76555 : svst1_f64(pgl, reinterpret_cast<float64_t*>(dst + dst_stride * 5), f2);
679 : 84868 : svst1_f64(pgl, reinterpret_cast<float64_t*>(dst + dst_stride * 6), d2);
680 : 84868 : svst1_f64(pgl, reinterpret_cast<float64_t*>(dst + dst_stride * 7), h2);
681 :
682 : 86136 : svst1_f64(pgh, reinterpret_cast<float64_t*>(dst + dst_stride * 8) - 2, a2);
683 : 86108 : svst1_f64(pgh, reinterpret_cast<float64_t*>(dst + dst_stride * 9) - 2, e2);
684 : 86004 : svst1_f64(pgh, reinterpret_cast<float64_t*>(dst + dst_stride * 10) - 2, c2);
685 : 86004 : svst1_f64(pgh, reinterpret_cast<float64_t*>(dst + dst_stride * 11) - 2, g2);
686 : 94500 : svst1_f64(pgh, reinterpret_cast<float64_t*>(dst + dst_stride * 12) - 2, b2);
687 : 94808 : svst1_f64(pgh, reinterpret_cast<float64_t*>(dst + dst_stride * 13) - 2, f2);
688 : 97830 : svst1_f64(pgh, reinterpret_cast<float64_t*>(dst + dst_stride * 14) - 2, d2);
689 : 97830 : svst1_f64(pgh, reinterpret_cast<float64_t*>(dst + dst_stride * 15) - 2, h2);
690 : 97833 : }
691 :
692 : 41518 : inline void transpose_16x16_kernel(ov::float16* dst, ov::float16* src, size_t dst_stride, size_t src_stride) {
693 : // check for SVE256
694 : 41518 : if (svcnth() == 16) {
695 : 41518 : transpose_8x16_kernel(reinterpret_cast<float16_t*>(dst),
696 : reinterpret_cast<float16_t*>(src),
697 : dst_stride,
698 : src_stride);
699 : 48957 : transpose_8x16_kernel(reinterpret_cast<float16_t*>(dst + 8),
700 : reinterpret_cast<float16_t*>(src + 128),
701 : dst_stride,
702 : src_stride);
703 : } else {
704 : 0 : for (size_t i = 0; i < 16; i++) {
705 : 0 : for (size_t j = 0; j < 16; j++) {
706 : 0 : dst[i * dst_stride + j] = (src[i + j * src_stride]);
707 : }
708 : }
709 : }
710 : 56641 : }
711 :
712 : 0 : inline void transpose_8x8_kernel(float* src, size_t ld_src, float* dst, size_t ld_dst) {
713 : // load from src to registers
714 : // a: a0 a1 a2 a3 a4 a5 a6 a7
715 : // b: b0 b1 b2 b3 b4 b5 b6 b7
716 : // c: c0 c1 c2 c3 c4 c5 c6 c7
717 : // d: d0 d1 d2 d3 d4 d5 d6 d7

```

```

718 : // e: e0 e1 e2 e3 e4 e5 e6 e7
719 : // f: f0 f1 f2 f3 f4 f5 f6 f7
720 : // g: g0 g1 g2 g3 g4 g5 g6 g7
721 : // h: h0 h1 h2 h3 h4 h5 h6 h7
722 0 : svfloat32_t a = svld1_f32(svptrue_b8(), &src[0 * ld_src]);
723 0 : svfloat32_t b = svld1_f32(svptrue_b8(), &src[1 * ld_src]);
724 0 : svfloat32_t c = svld1_f32(svptrue_b8(), &src[2 * ld_src]);
725 0 : svfloat32_t d = svld1_f32(svptrue_b8(), &src[3 * ld_src]);
726 0 : svfloat32_t e = svld1_f32(svptrue_b8(), &src[4 * ld_src]);
727 0 : svfloat32_t f = svld1_f32(svptrue_b8(), &src[5 * ld_src]);
728 0 : svfloat32_t g = svld1_f32(svptrue_b8(), &src[6 * ld_src]);
729 0 : svfloat32_t h = svld1_f32(svptrue_b8(), &src[7 * ld_src]);
730 : // unpacking and interleaving 32-bit elements
731 : // a0 b0 a1 b1 a4 b4 a5 b5
732 : // a2 b2 a3 b3 a6 b6 a7 b7
733 : // c0 d0 c1 d1 ...
734 : // c2 d2 c3 d3 ...
735 : // e0 f0 e1 f1 ...
736 : // e2 f2 e3 f3 ...
737 : // g0 h0 g1 h1 ...
738 : // g2 h2 g3 h3 ...
739 0 : svfloat32_t ta = svtrn1_f32(a, b);
740 0 : svfloat32_t tb = svtrn2_f32(a, b);
741 0 : svfloat32_t tc = svtrn1_f32(c, d);
742 0 : svfloat32_t td = svtrn2_f32(c, d);
743 0 : svfloat32_t te = svtrn1_f32(e, f);
744 0 : svfloat32_t tf = svtrn2_f32(e, f);
745 0 : svfloat32_t tg = svtrn1_f32(g, h);
746 0 : svfloat32_t th = svtrn2_f32(g, h);
747 : // unpacking and interleaving 64-bit elements
748 : // a0 b0 c0 d0 a4 b4 c4 d4
749 : // a1 b1 c1 d1 ...
750 : // a2 b2 c2 d2 ...
751 : // a3 b3 c3 d3 ...
752 : // e0 f0 g0 h0 e4 f4 g4 h4
753 : // e1 f1 g1 h1 ...
754 : // e2 f2 g2 h2 ...
755 : // e3 f3 g3 h3 ...
756 0 : a = svreinterpret_f32_f64(svtrn1_f64(svreinterpret_f64_f32(ta), svreinterpret_f64_f32(tc)));
757 0 : b = svreinterpret_f32_f64(svtrn2_f64(svreinterpret_f64_f32(ta), svreinterpret_f64_f32(tc)));
758 0 : c = svreinterpret_f32_f64(svtrn1_f64(svreinterpret_f64_f32(tb), svreinterpret_f64_f32(td)));
759 0 : d = svreinterpret_f32_f64(svtrn2_f64(svreinterpret_f64_f32(tb), svreinterpret_f64_f32(td)));
760 0 : e = svreinterpret_f32_f64(svtrn1_f64(svreinterpret_f64_f32(te), svreinterpret_f64_f32(tg)));
761 0 : f = svreinterpret_f32_f64(svtrn2_f64(svreinterpret_f64_f32(te), svreinterpret_f64_f32(tg)));
762 0 : g = svreinterpret_f32_f64(svtrn1_f64(svreinterpret_f64_f32(tf), svreinterpret_f64_f32(th)));
763 0 : h = svreinterpret_f32_f64(svtrn2_f64(svreinterpret_f64_f32(tf), svreinterpret_f64_f32(th)));
764 : // shuffle 128-bits (composed of 4 32-bit elements)
765 : // a0 b0 c0 d0 e0 f0 g0 h0
766 : // a1 b1 c1 d1 ...
767 : // a2 b2 c2 d2 ...
768 : // a3 b3 c3 d3 ...
769 : // a4 b4 c4 d4 ...
770 : // a5 b5 c5 d5 ...
771 : // a6 b6 c6 d6 ...
772 : // a7 b7 c7 d7 ...
773 0 : svfloat32_t t1a = svext_f32(a, a, 4);
774 0 : svfloat32_t t1b = svext_f32(b, b, 4);
775 0 : svfloat32_t t1c = svext_f32(c, c, 4);
776 0 : svfloat32_t t1d = svext_f32(d, d, 4);
777 0 : ta = svext_f32(t1a, e, 4);
778 0 : tb = svext_f32(t1b, f, 4);
779 0 : tc = svext_f32(t1c, g, 4);
780 0 : td = svext_f32(t1d, h, 4);
781 0 : te = svsel_f32(svptrue_pat_b32(SV_VL4), t1a, e);
782 0 : tf = svsel_f32(svptrue_pat_b32(SV_VL4), t1b, f);
783 0 : tg = svsel_f32(svptrue_pat_b32(SV_VL4), t1c, g);
784 0 : th = svsel_f32(svptrue_pat_b32(SV_VL4), t1d, h);
785 : // Store the transposed result in destination
786 0 : svst1_f32(svptrue_b8(), &dst[0 * ld_dst], ta);
787 0 : svst1_f32(svptrue_b8(), &dst[1 * ld_dst], tc);
788 0 : svst1_f32(svptrue_b8(), &dst[2 * ld_dst], tb);
789 0 : svst1_f32(svptrue_b8(), &dst[3 * ld_dst], td);
790 0 : svst1_f32(svptrue_b8(), &dst[4 * ld_dst], te);
791 0 : svst1_f32(svptrue_b8(), &dst[5 * ld_dst], tg);
792 0 : svst1_f32(svptrue_b8(), &dst[6 * ld_dst], tf);
793 0 : svst1_f32(svptrue_b8(), &dst[7 * ld_dst], th);
794 0 : }
795 :
796 0 : inline void transpose_16x16_kernel(float* dst, float* src, size_t dst_stride, size_t src_stride) {
797 0 : transpose_8x8_kernel(src, src_stride, dst, dst_stride);
798 0 : transpose_8x8_kernel(src + 8, src_stride, dst + 8 * dst_stride, dst_stride);
799 0 : transpose_8x8_kernel(src + 8 * src_stride, src_stride, dst + 8, dst_stride);
800 0 : transpose_8x8_kernel(src + 8 * src_stride + 8, src_stride, dst + 8 * dst_stride + 8, dst_stride);
801 0 : }
802 :
803 : #else
804 :
805 : template <typename TSRC, typename TDST>
806 0 : inline void transpose_16x16_kernel(TDST* dst, TSRC* src, size_t dst_stride, size_t src_stride) {
807 0 : for (size_t i = 0; i < 16; i++) {
808 0 : for (size_t j = 0; j < 16; j++) {
809 0 : dst[i * dst_stride + j] = static_cast<TDST>(src[i + j * src_stride]);
810 : }
811 : }
812 0 : }
813 :
814 : template <typename TSRC, typename TDST>
815 : inline void transpose_16xK_kernel(TDST* dst, TSRC* src, size_t K, size_t dst_stride, size_t src_stride) {
816 : for (size_t i = 0; i < K; i++) {
817 : for (size_t j = 0; j < 16; j++) {
818 : dst[i * dst_stride + j] = static_cast<TDST>(src[i + j * src_stride]);
819 : }
820 : }
821 : }

```

```
822 :  
823 : #endif  
824 :  
825 : } // namespace ov::Extensions::Cpu::XARCH
```

Generated by: [LCOV version 2.3-beta](#)